

PBL 06: 로드 밸런서와 오토 스케일링을 적용한 확장 가능한 애플리케이션 환경 구축 보고서

정하은

1. 개요

본 보고서는 웹 및 애플리케이션 서비스가 분리된 아키텍처의 한계를 분석하고, **로드 밸런싱(Load Balancing)**과 **오토 스케일링(Auto Scaling)**을 적용하여 서비스의 확장성과 안정성을 극대화하는 재설계 방안을 제안한다. 또한, 데이터베이스 계층의 고가용성(High Availability)을 강화하기 위해 Amazon RDS Multi-AZ 배포를 포함한다. 이를 통해 고객에게 안정적인 비즈니스 애플리케이션을 제공하고, 변화하는 트래픽에 유연하게 대응할 수 있는 클라우드 환경을 구축하는 데 중점을 두었다.

2. 문제 정의 및 요구사항

웹과 애플리케이션 서비스의 결합도를 해제하고 아키텍처를 분리했지만, 관리자는 여전히 애플리케이션의 안전성과 확장성 측면에서 한계를 인지하고 있으며 단일 인스턴스 장애 시 서비스 중단 위험, 트래픽 급증 시 수동 확장 필요성 등이 주요 문제이다. 이에 따라, 고객에게 안정된 비즈니스 애플리케이션을 서비스하기 위해 다음의 개선이 요구된다.

- 로드 분산 및 오토 스케일링을 통한 웹 및 애플리케이션 계층의 확장성 및 안정성 확보
- 데이터베이스 계층의 고가용성 강화
- 기존 아키텍처 구성
 - VPC 구역 안에 Public Subnet, Private Subnet, Private Subnet이 각각 세 개 존재 (가용 영역별 구성)
 - Public Subnet 안에는 Web (단일 또는 소수 인스턴스/컨테이너)
 - Private Subnet 안에는 App (단일 또는 소수 인스턴스/컨테이너)
 - Private Subnet 안에는 RDS (Single-AZ 배포 가능성)


3. 고가용성 및 확장성 개념 이해

클라우드 아키텍처 설계에서 고가용성(High Availability, HA)과 확장성(Scalability)은 서비스의 안정성과 지속성을 보장하는 핵심 요소이다.

- **고가용성(HA)** : 시스템이나 서비스가 장애 발생 시에도 중단 없이 계속 운영되거나, 최소한의 중단으로 빠르게 복구될 수 있는 능력이다. AWS에서는 여러 가용 영역(Availability Zone, AZ)에 리소스를 분산 배치하고, 자동 페일오버 기능을 활용하여 구현한다.
- **확장성(Scalability)** : 시스템이 증가하는 수요를 처리하기 위해 리소스 용량을 효율적으로 늘리거나 줄일 수 있는 능력이다.
 - **수직 확장(Scale Up)** : 단일 인스턴스의 성능(CPU, 메모리)을 높이는 방식이다. 물리적 한계가 있다.
 - **수평 확장(Scale Out)** : 동일한 기능을 하는 인스턴스를 여러 개 추가하여 분산 처리하는 방식이다. 클라우드 환경에서 주로 사용되며, 무한한 확장이 가능하다.

4. 기존 아키텍처 분석 및 개선 필요 부분 식별

PBL 05에서 웹과 애플리케이션 서비스가 분리되었지만, 여전히 다음과 같은 한계점이 존재한다.




- 웹/애플리케이션 서비스의 단일 장애점 및 확장성 한계
 - Public Subnet의 Web과 Private Subnet의 App이 여전히 단일 인스턴스 또는 소수의 인스턴스로만 운영된다면, 해당 인스턴스에 장애 발생 시 서비스 중단 위험이 크다.
 - 트래픽이 급증할 경우, 수동으로 인스턴스를 추가하거나 인스턴스 유형을 변경해야 하므로 대응이 민첩하지 못하다. 이는 곧 서비스 지연이나 중단으로 이어질 수 있다.
- 데이터베이스의 가용성 부족
 - Amazon RDS는 관리형 서비스이지만, 기본 Multi-AZ가 아닌 Single-AZ 배포일 경우, 해당 가용 영역에 장애가 발생하면 데이터베이스에 접근할 수 없어 애플리케이션 전체가 중단될 수 있다.

이러한 문제점들을 해결하고 고객에게 안정적인 서비스를 제공하기 위해, 웹/애플리케이션 계층에는 로드 밸런싱과 자동 확장을, 데이터베이스 계층에는 Multi-AZ구성을 적용하는 것이 필요하다.

5. 재설계된 아키텍처 제안 및 적용 기술

기존의 분리된 아키텍처에 로드 밸런싱, 오토 스케일링, 그리고 RDS Multi-AZ를 적용하여 확장성과 안정성을 극대화한 아키텍처를 제안하고자 한다.



5.1. Application Load Balancer (ALB) 적용

- **역할** : 들어오는 트래픽을 여러 대상(EC2 인스턴스, 컨테이너 등)에 자동으로 분산하여 단일 서버에 대한 부하를 줄이고, 특정 대상의 장애 시 트래픽을 건강한 대상으로만 라우팅하여 서비스 중단을 방지한다.
- **적용**
 - **외부 ALB** : Public Subnet에 배치되어 외부 인터넷으로부터의 모든 HTTP/HTTPS 트래픽을 받아 Private Subnet 내의 웹 서비스 인스턴스/컨테이너로 분산한다.
 - **내부 ALB** : Private Subnet에 배치되어 웹 서비스에서 애플리케이션 서비스 로의 내부 트래픽을 효율적으로 분산한다.
- **장점** : 트래픽 분산을 통한 성능 향상, 헬스 체크를 통한 장애 인스턴스 격리, 여러 가용 영역에 걸친 배포로 고가용성 확보.

5.2. Auto Scaling Group (ASG) 적용

- **역할** : 정의된 정책(예: CPU 사용률, 네트워크 인/아웃)에 따라 EC2 인스턴스(또는 컨테이너 Task)의 수를 자동으로 조절하여 트래픽 변화에 유연하게 대응하고, 여러 가용 영역에 인스턴스를 분산 배치하여 고가용성을 확보한다.
- **적용**
 - **웹 서비스용 ASG** : Private Subnet의 여러 가용 영역에 걸쳐 웹 서비스 인스턴스를 배포하고, 외부 ALB의 타겟 그룹과 연결한다. 트래픽 증가 시 자동으로 웹 서비스 인스턴스를 확장한다.
 - **애플리케이션 서비스용 ASG** : Private Subnet의 여러 가용 영역에 걸쳐 애플리케이션 서비스 인스턴스를 배포하고, 내부 ALB의 타겟 그룹과 연결한다. 비즈니스 로직 처리 부하 증가 시 자동으로 애플리케이션 서비스 인스턴스를 확장한다.
- **장점** : 트래픽 급증 시 서비스 중단 방지, 트래픽 감소 시 리소스 자동 축소로 비용 최적화, 여러 AZ에 걸친 인스턴스 분산으로 장애 복원력 향상.

5.3. Amazon RDS Multi-AZ 배포 적용

- **역할** : 데이터베이스의 고가용성을 극대화한다. 주 데이터베이스 인스턴스와 동일한 데이터를 다른 가용 영역에 동기식으로 복제된 대기(Standby) 인스턴스를 유지한다.
- **적용** : 기존 Amazon RDS MySQL 인스턴스를 Multi-AZ 배포로 구성합니다. 이는 RDS 설정에서 간단히 활성화할 수 있다.
- **장점** : 주 인스턴스 장애(하드웨어, 네트워크, AZ 장애 등) 발생 시 자동으로 대기 인스턴스로 페일오버되어 애플리케이션 가동 중단 시간을 최소화한다. 데이터 손실 위험을 줄이고, 데이터베이스 계층의 안정성을 크게 향상시킨다.

5.4. 기타 네트워크 및 보안 구성

- **NAT Gateway** : Private Subnet 내의 웹 및 애플리케이션 서비스 인스턴스/컨테이너가 외부 인터넷과 안전하게 통신할 수 있도록 Public Subnet에 배치된 NAT Gateway를 계속 활용한다.
- **보안 그룹 (Security Groups)** : 각 계층(ALB, 웹 서비스 ASG, 애플리케이션 서비스 ASG, RDS)에 적절한 보안 그룹을 적용하여 최소 권한 원칙에 따라 트래픽을 제어하고, 내부 통신(예: 웹 → 앱, 앱 → DB)에 필요한 포트만 개방하여 보안을 강화한다.

6. 결론

본 보고서에서 제안된 아키텍처 재설계는 로드 밸런싱, 오토 스케일링, 그리고 RDS Multi-AZ 배포를 통해 애플리케이션의 확장성과 안정성을 확보할 수 있는 방안을 제시한다.

- **서비스 중단 최소화** : ALB와 ASG의 헬스 체크 및 자동 복구 기능, RDS Multi-AZ의 자동 페일오버를 통해 단일 장애점을 제거하고, 예측 불가능한 장애에도 서비스가 지속될 수 있도록 보장한다.
- **비용 효율적인 성능 유지** : ASG의 자동 확장/축소 기능은 트래픽 변화에 따라 리소스를 최적화하여 불필요한 비용 낭비를 줄이면서도 항상 최적의 성능을 유지할 수 있게 한다.
- **향상된 고객 경험** : 트래픽 급증 시에도 지연 없이 안정적인 서비스를 제공하여 고객 만족도를 높인다.
- **운영 효율성 증대** : 대부분의 인프라 관리 및 스케일링 작업이 자동화되어 관리자의 운영 부담을 줄인다.

결론적으로, 로드 밸런서와 오토 스케일링, 그리고 RDS Multi-AZ는 현대 클라우드 애플리케이션의 필수적인 구성 요소이며, 이러한 기술들을 적용함으로써 비즈니스 요구사항에 유연하게 대응하고, 고객에게 안정적이고 확장 가능한 서비스를 제공할 수 있는 견고한 클라우드 아키텍처를 구축할 수 있다.